

РАЗБОР СЛУЧАЯ

Доклад залу, у которого нет общего языка.

Выучить португальский как следует — вот настоящий ответ, и тут я медленнее, чем хотел бы. Пока же есть ответ инженерный: дать залу субтитры на его языке, а мне — вопросы на моём. Этот доклад о том, **как** это было сделано, а не о том, что оно умеет.

Живые субтитры для встреч · сделано за дни, не месяцы · работает бесплатно

Переписка работает. Трудно с речью.

- Разработчики переписываются по-английски, и это работает.
- Живая речь — **вот где ломается**, начиная с меня. Мой португальский пока в работе, поэтому на встрече я теряю вопросы, а не слайды.
- И не только со мной: английский на скорости живой речи удобен в зале не всем одинаково.
- У Teams есть живые субтитры. Но **переведённые** требуют Premium, и он нужен каждому участнику.

Форма задачи

Доклад — это вещание **один ко многим** с хвостом вопросов **многие к одному**. У этих двух направлений совершенно разные требования, и это оказалось самым важным, что стоило заметить.

Я → зал

важна задержка

Зал → я


важна точность

Та же затея с разницей в два года

	ТОГДА	СЕЙЧАС
Распознавание речи	Платный облачный сервис, ключ, оплата по часам	Встроено в браузер. Бесплатно, без лимитов.
Перевод	Платный API, поход по сети на каждую фразу	Работает на устройстве . Без сети, без ключа, без квоты.
Определение языка	Отдельная модель, своя настройка, свои отказы	Одна фраза в промпте.
Сделать это	Недели команды. Ради проблемы одного человека никто бы не согласовал.	Дни одного человека. Согласовывать не у кого.

Интересна последняя строка. **Экономика изменилась раньше технологии.** Задачи, которые касаются одного человека, никогда не стоили проекта. Теперь они стоят одного вечера — и потому решаются.

Я спрашивал не одну модель. Я собирал совет.



- Задать **один вопрос 2–4 моделям**, независимо. Дёшево и параллельно.
- Выбрать лучший план. Здесь первый был уже хорош, а второй явно не туда — **ценно именно сравнение**, а не среднее.
- Отдать победителя **остальным как критикам**, а не как авторам.
- Вернуть критику **исходному автору**.

У этого теперь есть название

LLM Council Карпатого — параллельный опрос, взаимная рецензия, синтез. Я пользовался **сопоставительным** вариантом: рецензентам велено искать изъяны, а не соглашаться.

Почему работает: слепое пятно одной модели становится итоговым ответом. У критика с другим слепым пятном этого пятна нет.

Что критики действительно изменили

ПЕРВЫЙ ПЛАН	ИТОГ	ПОЧЕМУ РАЗВЕРНУЛОСЬ
Azure Speech как движок	Никаких платных сервисов	Требует карту даже на бесплатном плане. Коллеги этим не воспользуются.
Принимать PPTX и конвертировать LibreOffice	Только PDF	Убрало сервер, разбор OOXML и целый класс ошибок вёрстки.
Свой ресемплер звука и тест к нему	Один аргумент конструктора	Браузер уже умеет ресемплить. День работы, которого не требовалось.
Языки зашиты в код	Объект профиля	«У твоих коллег другие языки». Об этом я вообще не подумал.

Каждая правка **убрала** работу. Критики не добавляли возможностей — они вычёркивали планы. Это самое ценное, что умеет рецензент, и ровно то, чего одна воодушевлённая модель себе не сделает.

Артефакт — это ТЗ. Код идёт следом.

- Я писал и переписывал **техзадание**, а не промпты. Требования, критерии приёмки, явные не-цели.
- Каждый разворот с прошлого слайда **записан там вместе с причиной**. Через полтора месяца я не буду заново спорить про Azure.
- В индустрии это зовут **spec-driven development**, и в 2026-м свой вариант выкатил каждый инструмент с агентами.
- Причина совпадает с моим опытом: агенты хорошо пишут код и **плохо угадывают замысел**. Отказ — это снос, а не синтаксис.

Что дало разницу

Не-цели. «Без RPTX. Без аккаунтов. Без сервера.» Записанные, они перестают возвращаться.

Критерии приёмки как тесты. «В стенограмме нет фраз на чужом языке» — проверяемо. «Хорошее качество» — нет.

Журнал решений. ТЗ заканчивается таблицей того, что развернули и почему, — самая перечитываемая страница.

Измерь до того, как строить. Одна страница кода.

До приложения я написал один HTML-файл, который проверял каждое допущение на том самом ноутбуке. Это заняло минуты и изменило архитектуру.

147 ms

Распознавание в браузере, от конца фразы до финального текста. Я закладывал **1000 мс**.

~600


Запросов к облачной модели на двухчасовой доклад при моём реальном темпе речи. Почти наверняка выше бесплатной суточной квоты.

0

Нужных драйверов, серверов и аккаунтов — все три риска, под которые я планировал обходные пути, не существовали.

Оба числа указали в одну сторону и **развернули выбор по умолчанию**. Я собирался пустить свою речь через облачную модель. Замер сказал: бери браузер, а облако оставь залу. В двадцать раз быстрее и бесплатно.

Одно окно. Зал читает вместе с вами.




Этот слайд говорил «два окна»

В первом варианте было второе, личное окно: лог мой, зал видит только слайд.

Потом очевидный вопрос: **а лог для кого?** Для тех, кому нужно прочесть, что я только что сказал. Личному окну стало нечего хранить, и оно было удалено.

Всё в одной расшаренной картинке: слайд, субтитры, переписка. **Без бота, без Premium, ничего не ставить.**

Два канала, два движка, один контракт



слой	ВЫБОР	ПОЧЕМУ ОН
Слайды	pdf.js в canvas	Единственный надёжный способ отрисовать слайд как в печати
Состояние	Один стор Zustand	Слайды, лог и разметка в одном месте — без проброса пропсов
Разметка	SVG поверх canvas	PDF не меняется никогда. Попадание считает браузер.
Хранение	IndexedDB + localStorage	Лог переживает случайный F5; ничего не покидает машину

Пусть выбирает человек, а выбор пусть выбирает движок

	ПИН — ЯЗЫК НАЗЫВАЮ Я	АВТО — ЯЗЫК ОПРЕДЕЛЯЕТ МОДЕЛЬ
Задержка субтитра	~0.15 s	~3 s
Текст по ходу речи	да	нет — фраза целиком
Суточные лимиты	нет	общая квота
Ключ API	не нужен	обязателен
Мне надо помнить	нажать перед сменой языка	ничего

Микрофон в пине, зал в авто. Я знаю, на каком языке сейчас заговорю. Я не могу знать, на каком придёт следующий вопрос.

Настройка не косметическая — она **выбирает движок**. Приложение не спрашивает «какой провайдер?»; оно задаёт вопрос, на который человек может ответить, а остальное выводит само.

Какой модный приём и когда

ПРИЁМ	ЧТО ЭТО НА ДЕЛЕ	СТОИТ ТОГО, КОГДА	ЛИШНИЙ ГРУЗ, КОГДА
✓ Совет моделей	Несколько моделей отвечают, потом критикуют друг друга	Архитектура и необратимые решения	Рутинный код, который проще прочитать
✓ От спецификации	Версионизируемое ТЗ — источник истины, код порождается из него	Всё, что вы будете менять и через месяц	Скрипт, который запускают один раз
✓ Стенд разработки	Заглушка провайдера и роут с записанным сценарием	На входе живой человек, железо или платный API	Чистые функции — просто вызовите их
✓ Сначала разведка	Одноразовая страница, меряющая допущения на реальной машине	Вы вот-вот заложитесь на выдуманное число	Число задокументировано и стабильно
• Эвалы	Набор тестов с оценкой, ловящий просадки качества	Выход модели и есть продукт, и он выкатывается регулярно	Разовый инструмент, человек в цикле каждый запуск
• Голосовой помощник	Сессия речь-в-речь по WebRTC, доли секунды	Руки и глаза заняты — за рулём, у доски, в операционной	Печатать быстрее и тише, а так почти всегда

✓ — то, чем проект пользовался на деле. Крепче всего я защищал бы заглушку провайдера: **без неё каждая правка интерфейса требует живого человека, говорящего в микрофон.**

Оркестрация агентов: я ею не пользовался

Шаблоны 2026-го устоялись: супервизор, конвейер, параллельное разветвление, маршрутизатор, иерархия, оценщик-оптимизатор. Я не использовал ни одного и считаю, что правильно.

- **Почему нет:** одно приложение, один разработчик, работа почти целиком последовательная. Оркестрация покупает параллелизм, которого мне некуда девать.
- **Когда окупается:** механическая правка по многим файлам — миграции, аудиты, обходы. Разветвление под супервизором.
- **Когда окупится здесь, потом:** проход рецензии. Несколько критиков по разным осям, разом, — это ровно мой совет, только автоматизированный вместо копипасты.

Что улучшится вместе с моделями

- Перевод на устройстве станет лучше → бесплатный путь перестанет быть компромиссом и станет выбором по умолчанию.
- Поточковые модели речи созреют → определение языка и малая задержка перестанут быть разменом, и моё центральное решение **испарится**.
- Дешёвые аудиотокены → довод про квоту исчезает.
- Длиннее контекст → вся встреча не только расшифрована, но и пересказана.

Интерфейс провайдера существует ровно затем, чтобы **ничто из этого не требовало переписывать приложение** — только добавить файл.